





MODELAÇÃO E PREVISÃO DO CONSUMO MENSAL DE ELETRICIDADE EM ESPANHA

Apresentacao com max de 10min

+ logo uni + autor



ENQUADRAMENTO / MOTIVAÇÃO



ANÁLISE EXPLORATÓRIA



- Consumo mensal de eletricidade (GWh) em Espanha
- Janeiro de 2008 a fevereiro de 2025 (206 observações)
- Sazonalidade? Sim
- Tendência? Talvez
- Variância constante? Talvez
- Outliers? 2020
- Separação em teste e treino (80/20)

ESTACIONARIEDADE

Heterocedasticidade

- Transformação Box-Cox
- ```
studentized Breusch-Pagan test


data: model
BP = 0.35006, df = 1, p-value = 0.5541
Rej. H_0 : Não há evidência de heterocedasticidade
```
- Nenhuma transformação aplicada




# ESTACIONARIEDADE

## Sazonalidade e Tendência








Diagnóstico da Série Temporal



Diagnóstico após diferenciação sazonal (lag = 12)



Diferenciação sazonal (lag = 12) e primeira diferenciação (lag = 1)



# ESTACIONARIEDADE

```
KPSS Unit Root Test #

Test is of type: mu with 4 lags.

Value of test-statistic is: 0.0199

Critical value for a significance level of:
10pct 5pct 2.5pct 1pct
critical values 0.347 0.463 0.574 0.739
```

```
Warning in adf.test(diff(diff(ts_train, lag = 12),
differences = 1)): p-value smaller than printed p-value

Augmented Dickey-Fuller Test

data: diff(diff(ts_train, lag = 12), differences = 1)
Dickey-Fuller = -6.9048, Lag order = 5, p-value = 0.01
alternative hypothesis: stationary
```

Ambos os testes confirmam a estacionariedade da série após a diferenciação de ordem 1 e 12

## PROPOSTAS DE MODELOS

---

SARIMA

---

GARCH

---

ETS


---

STLM

# SARIMA


3 modelos, tendo em conta:

- Análise ACF e PACF
  - SARIMA(1,1,1)(1,1,1)[12]
- Análise sistemática, critério AICc
  - SARIMA(2,0,2)(2,1,0)[12]
- Análise sistemática, critério AICc, com  $d = D = 1$ 
  - SARIMA(0,1,2)(3,1,0)[12]





# SARIMA



- Apesar dos modelos parecerem ajustar-se bem aos dados de treino, todos os testes de Ljung-Box revelaram autocorrelação significativa nos resíduos.
- Outras variantes foram testadas, mas apresentaram desempenhos ainda inferiores.

# SARIMA

## Ljung-Box test

##

## data: Residuals from ARIMA(1,1,1)(1,1,1)[12]

## Q\* = 31.304, df = 20, p-value = 0.0513

##

## Model df: 4 Total lags used: 24

## Shapiro-Wilk normality test



##

## data: residuals(fit\_arima)

## W = 0.97568, p-value = 0.005097

## Kolmogorov-Smirnov test

Q-Q Plot dos Resíduos do SARIMA(1,1,1)(1,1,1)[12]



##

## data: residuals(fit\_arima)

## D = 0.083543, p-value = 0.1969

## alternative hypothesis: two-sided




# GARCH

- Meter print do teste

```
ARCH LM-test; Null hypothesis: no ARCH effects
##
data: residuals(fit_arima)
Chi-squared = 9.7974, df = 12, p-value = 0.6337
```

# ETS

- Modelo ajustado tendo em conta o critério AICc: ETS(M,N,A)




- Adicionar ljunbox test


# STLM

- STLM(ARIMA)


Decomposição STLM do Consumo Elétrico



# STLM



Q-Q Plot dos Resíduos do STLM(ARIMA)



- Meter ljobx test + normalidades




## PREVISÃO DE OBSERVAÇÕES FUTURAS


- ARIMA(1,1,1)(1,1,1)[12]
- STLM(ARIMA)

# PREVISÃO DE OBSERVAÇÕES FUTURAS


Previsão vs Série Completa - SARIMA(1,1,1)(1,1,1)[12]




Previsão vs Série Completa - STLM(ARIMA)



Previsão vs Conjunto de Teste - SARIMA(1,1,1)(1,1,1)[12]



Previsão vs Conjunto de Teste - STLM(ARIMA)







## PREVISÃO DE OBSERVAÇÕES FUTURAS


- Meter métricas de teste e treino para cada um deles (tabela)

# PREVISÃO DE OBSERVAÇÕES FUTURAS

## Intervalos de previsão

- Ambos os modelos com cobertura total
- Amplitude média:
  - SARIMA: 4378
  - STLM: 3639

Comparação de Intervalos de Previsões: SARIMA vs STLM





# DISCUSSÃO

- Escolha do melhor modelo + justificação